

Clasificación de Tumores de Mama con Machine Learning: Un Estudio Comparativo sobre el Dataset Wisconsin

Leonardo Jose Amaris Dominguez Estudiante, Ingeniería de Sistemas
 Alejandro Orrego Roldan Estudiante, Ingeniería de Sistemas
 Luis David Martinez Estudiante, Ingeniería de Sistemas

I. DESCRIPCIÓN DEL PROBLEMA

El cáncer de mama es una de las enfermedades con mayor incidencia a nivel mundial, y su detección temprana es determinante para mejorar el pronóstico del paciente. Este trabajo aborda la clasificación automática de tumores como malignos o benignos a partir de características morfológicas extraídas de imágenes de biopsias por aspiración con aguja fina (FNA).

El dataset utilizado es el *Breast Cancer Wisconsin (Diagnostic)*, compuesto por 569 muestras y 30 variables predictoras continuas sin valores faltantes. Las variables se organizan en tres grupos — media, error estándar y peor valor — de 10 características del núcleo celular: radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal. La variable objetivo *Diagnosis* es binaria, codificada como 1 (maligno) y 0 (benigno), con una distribución de 357 muestras benignas (62.7%) y 212 malignas (37.3%). Dado que las variables presentan escalas distintas, se aplicará normalización previa al entrenamiento.

El paradigma seleccionado es el aprendizaje supervisado de clasificación binaria, puesto que se dispone de etiquetas conocidas para todas las muestras y el objetivo es predecir la clase de nuevas observaciones.

II. ESTADO DEL ARTE

La clasificación de tumores de mama utilizando el dataset Wisconsin Diagnostic Breast Cancer (WDBC) ha sido ampliamente estudiada en la literatura de machine learning. A continuación se presentan cuatro trabajos representativos que abordan este problema desde distintas perspectivas.

Salama et al. (2012) realizaron una comparación de cinco clasificadores —Naive Bayes, MLP, J48, SMO y KNN— sobre tres versiones del dataset Wisconsin (WBC, WDBC y WPBC). Emplearon validación cruzada de 10 pliegues en la herramienta WEKA y evaluaron el desempeño mediante accuracy y matriz de confusión. Para el WDBC, el clasificador SMO (SVM) individual obtuvo el mejor resultado con 97.71% de accuracy, explorando además la fusión de clasificadores para mejorar la robustez del diagnóstico.

Omondigbe et al. (2019) propusieron un enfoque híbrido que combina técnicas de reducción de dimensión con clasificadores de ML sobre el WDBC. Evaluaron SVM con kernel RBF, ANN y Naive Bayes, aplicando métodos de selección y extracción de características como CFS, RFE, PCA y LDA. La validación se realizó mediante hold-out (70/30). La combinación SVM+LDA obtuvo el mejor desempeño con 98.82% de accuracy y un AUC-ROC de 0.9994, concluyendo

que la reducción de dimensión mejora significativamente la sensibilidad y especificidad de los modelos.

Agarap (2018) comparó seis algoritmos de ML sobre el WDBC utilizando la librería TensorFlow: GRU-SVM, regresión lineal, MLP, búsqueda por vecino más cercano, regresión Softmax y SVM. El desempeño se evaluó mediante accuracy, sensibilidad y especificidad. El MLP fue el modelo con mejor resultado, alcanzando 99.04% de accuracy, evidenciando que el WDBC es un dataset altamente separable donde las redes neuronales y los clasificadores lineales son muy competitivos.

Cakmak y Pacal (2025) evaluaron siete algoritmos modernos —SVM, Decision Tree, Random Forest, KNN y modelos de boosting como CatBoost, Gradient Boosting y XGBoost— con partición 70/30. SVM obtuvo el mejor resultado con 97.66%, mientras que KNN registró el desempeño más bajo con 80.00%. Los autores concluyen que la estructura del dataset favorece a los clasificadores basados en márgenes, y que los ensambles de árboles (boosting) ofrecen una alternativa robusta para la práctica clínica.

REFERENCES

- [1] G. I. Salama, M. B. Abdelhalim, and M. A. Zeid, "Breast cancer diagnosis on three different datasets using multi-classifiers," *International Journal of Computer and Information Technology*, vol. 1, no. 1, pp. 36–43, 2012.
- [2] D. A. Omondigbe, S. Veeramani, and A. S. Sidhu, "Machine learning classification techniques for breast cancer diagnosis," *IOP Conference Series: Materials Science and Engineering*, vol. 495, p. 012033, 2019.
- [3] A. F. M. Agarap, "On breast cancer detection: an application of machine learning algorithms on the Wisconsin Diagnostic Dataset," in *Proc. 2nd Int. Conf. Machine Learning and Soft Computing (ICMLSC)*, 2018, pp. 5–9.
- [4] Y. Cakmak and I. Pacal, "Enhancing breast cancer diagnosis: a comparative evaluation of machine learning algorithms using the Wisconsin dataset," *Journal of Operations Intelligence*, vol. 3, no. 1, pp. 180–201, 2025.