

Clasificación de Tumores de Mama con Machine Learning: Un Estudio Comparativo sobre el Dataset Wisconsin

Alejandro Orrego Roldán, Leonardo José Amaris Dominguez y Luis David Martínez Galindo,
Estudiantes, Ingeniería de Sistemas Universidad de Antioquia

Abstract—Este informe presenta un estudio comparativo exhaustivo sobre la clasificación de tumores de mama utilizando técnicas de Machine Learning (ML) aplicadas al dataset Wisconsin. El objetivo principal es desarrollar un sistema de predicción robusto que minimice los falsos negativos, un factor crítico en el diagnóstico oncológico. Se exploran cinco algoritmos de ML: Regresión Logística, Support Vector Machines (SVM), K-Nearest Neighbors (KNN), Random Forest y Redes Neuronales (MLP), evaluados bajo seis escenarios de ingeniería de características (Crudo, LASSO, Mutual Information, RFE, PCA y Fisher). La metodología de validación incluye una partición estratificada 80/20 para entrenamiento y prueba, y validación cruzada de 5 pliegues para la optimización de hiperparámetros. Las métricas de desempeño se centran en el Recall, Accuracy, Precision y F1-Score. Los resultados demuestran que la Red Neuronal MLP, combinada con la reducción de dimensionalidad mediante PCA (10 componentes) o selección de características LASSO, alcanza un Recall del 100% y una Accuracy del 100% en el conjunto de prueba independiente. Además, se evalúan técnicas de reducción de dimensión lineal (PCA) y no lineal (UMAP), confirmando que es posible reducir la complejidad del modelo en un 66.6% sin sacrificar la sensibilidad. Este estudio valida la viabilidad de los sistemas de ML como herramientas de apoyo al diagnóstico clínico, superando los resultados reportados en la literatura especializada y ofreciendo una solución de alta fidelidad para la detección temprana del cáncer de mama.

Index Terms—Machine Learning, Clasificación de Tumores de Mama, Dataset Wisconsin, Reducción de Dimensionalidad, PCA, UMAP, Redes Neuronales, Recall, Diagnóstico Asistido por Computadora (CAD), Oncología.

I. INTRODUCCIÓN

EL cáncer de mama representa uno de los desafíos más críticos en la salud pública global, siendo la principal causa de mortalidad por cáncer entre las mujeres en todo el mundo [4]. La detección temprana y precisa es el factor determinante para mejorar las tasas de supervivencia y reducir la agresividad de los tratamientos oncológicos. En la práctica clínica, la interpretación de biopsias por aspiración con aguja fina (FNA) requiere una alta precisión técnica para distinguir entre masas benignas y malignas [7]. Sin embargo, la variabilidad en la interpretación humana y la complejidad de los patrones morfológicos celulares pueden conducir a diagnósticos erróneos. En este contexto, el desarrollo de sistemas de Diagnóstico Asistido por Computadora (CAD) basados en **Machine Learning (ML)** surge no solo como una herramienta de apoyo, sino como un paradigma transformador que permite procesar grandes volúmenes de datos biomédicos con una objetividad y velocidad superiores a los métodos convencionales [3]. La utilidad de una solución basada en ML radica en su capacidad para identificar correlaciones no lineales y patrones sutiles en las características geométricas de

las células que podrían pasar inadvertidos para el ojo humano, optimizando así la toma de decisiones clínicas y minimizando la incidencia de falsos negativos [5].

A. Descripción del Problema y Contexto

El problema abordado en este estudio consiste en la clasificación binaria de tumores mamarios a partir de descriptores morfológicos extraídos de imágenes digitalizadas de FNA. El objetivo primordial es construir un sistema predictivo que maximice la sensibilidad o **Recall**, dado que en el ámbito oncológico, el costo clínico de omitir un caso maligno (Falso Negativo) es significativamente mayor que el de una evaluación adicional por un Falso Positivo [2]. Para lograr esto, se requiere un análisis riguroso de la frontera de decisión entre las clases, considerando la alta dimensionalidad de los datos y la posible redundancia entre las variables morfológicas. El equipo de trabajo ha planteado este proyecto como un estudio comparativo multiescenario, donde se evalúa el impacto de diferentes técnicas de ingeniería de características sobre el rendimiento de diversos algoritmos de aprendizaje.

B. Composición y Análisis de la Base de Datos

Para el desarrollo de este trabajo, se utilizó el **Breast Cancer Wisconsin (Diagnostic) Dataset**, obtenido del repositorio oficial de la UCI Machine Learning [1]. Esta base de datos es un estándar de oro en la literatura de ML para oncología debido a su calidad y estructura [6]. La composición detallada del dataset se presenta en la siguiente tabla:

TABLE I: Composición Detallada del Dataset

Atributo	Descripción
Número de Muestras	569 instancias
Número de Variables	30 características predictoras continuas
Variable Objetivo	Diagnosis (Maligno / Benigno)
Distribución de Clases	357 Benignos (62.74%), 212 Malignos (37.26%)
Datos Faltantes	0 (Dataset íntegro)

Las 30 variables predictoras se derivan de 10 características base medidas para cada núcleo celular: radio, textura, perímetro, área, suavidad, compacidad, concavidad, puntos cóncavos, simetría y dimensión fractal. Para cada una de estas características, se calculan tres valores: la media (mean), el error estándar (SE) y el "peor" valor o valor máximo (worst), resultando en las 30 dimensiones mencionadas [1].

En cuanto a la **codificación de datos**, se implementó una estrategia de transformación numérica estricta. La variable objetivo, originalmente categórica ('M' y 'B'), fue codificada mediante un esquema binario donde el valor 1 representa

tumores Malignos y el valor 0 representa tumores Benignos. Esta codificación es fundamental para la implementación de funciones de pérdida en redes neuronales y modelos probabilísticos. Dado que no se detectaron datos faltantes tras la auditoría inicial, no fue necesaria la aplicación de técnicas de imputación, preservando así la pureza estadística de las muestras originales. Sin embargo, debido a las diferencias en las escalas de medida, se aplicó un proceso de estandarización Z-score a todas las variables predictoras, asegurando que cada característica contribuya equitativamente al aprendizaje del modelo [3].

C. Paradigma de Aprendizaje y Justificación

El equipo de trabajo determinó que el paradigma de **Aprendizaje Supervisado** es el enfoque más apropiado y robusto para la solución de este problema. Esta decisión se justifica por la disponibilidad de etiquetas de diagnóstico verificadas para cada muestra, lo que permite el entrenamiento de modelos mediante la minimización de una función de error explícita. Dentro de este paradigma, se seleccionó una configuración de **Clasificación Binaria**, dado que el dominio del problema se restringe a dos estados mutuamente excluyentes (Maligno vs. Benigno) [4].

La justificación técnica de este abordaje se sustenta en tres pilares:

- 1) **Capacidad de Generalización:** Al contar con un dataset etiquetado, es posible implementar metodologías de validación cruzada para asegurar que el sistema no solo memorice los datos (overfitting), sino que aprenda patrones biológicos transferibles a nuevos pacientes.
- 2) **Evaluación de Riesgo Clínico:** El aprendizaje supervisado permite el ajuste fino de hiperparámetros orientados específicamente a la métrica de Recall, permitiendo penalizar con mayor rigor los errores de tipo II (Falsos Negativos), lo cual es imperativo en el diagnóstico de cáncer [5].
- 3) **Comparabilidad Algorítmica:** Este paradigma facilita la comparación sistemática entre modelos de diversa naturaleza matemática, desde regresiones lineales hasta redes neuronales multicapa (MLP), permitiendo identificar qué arquitectura captura mejor la complejidad de los datos oncológicos bajo diferentes escenarios de reducción de dimensionalidad.

Este estudio no solo busca clasificar, sino comprender cómo la transformación del espacio de características influye en la capacidad predictiva, estableciendo un marco de trabajo que garantiza rigor científico y utilidad clínica.

II. ESTADO DEL ARTE

La clasificación de tumores de mama mediante técnicas de aprendizaje de máquina ha sido un área de intensa investigación en la última década, particularmente utilizando el conjunto de datos Wisconsin. La literatura especializada en revistas de alto impacto como IEEE y Elsevier refleja una evolución desde modelos individuales simples hacia arquitecturas híbridas y sistemas de aprendizaje por conjuntos

(Ensemble Learning). A continuación, se analizan cuatro trabajos fundamentales que abordan el problema desde diversas perspectivas metodológicas.

A. Evaluación Comparativa de Técnicas de AutoML

En el estudio publicado en *Biomedical Signal Processing and Control* (Elsevier), Rashed et al. [8] proponen un sistema de diagnóstico automático evaluando siete técnicas de Aprendizaje de Máquina Automatizado (AutoML), incluyendo Lazy Predict y MATLAB Classification Learner. El trabajo utiliza un paradigma de **Aprendizaje Supervisado** aplicado a ocho bases de datos, destacando el dataset Wisconsin. Los autores emplean una metodología de validación basada en la partición de datos entrenamiento/prueba y validación cruzada para optimizar hiperparámetros. Las métricas de desempeño incluyen Accuracy, Precision, Recall y F1-score. Los resultados demostraron que Lazy Predict y MATLAB Classification Learner superaron a otros marcos de trabajo, alcanzando precisiones superiores al 97% en tareas de clasificación binaria, subrayando la eficiencia de los modelos de ensamble generados automáticamente frente a modelos individuales sin optimizar.

B. Integración de Modelos mediante Votación Ponderada

Martínez-Licort et al. [9], en su artículo de IEEE Access, presentan una metodología basada en el paradigma de **Aprendizaje por Conjuntos (Ensemble Learning)**. Utilizan el dataset WDBC (Wisconsin Diagnostic Breast Cancer) y aplican una etapa crítica de preprocesamiento que incluye estandarización y Análisis de Componentes Principales (PCA) para reducir la correlación entre variables. Los autores evalúan modelos de Regresión Logística (LR), Random Forest (RF), Naive Bayes (NB) y Support Vector Machines (SVM). La metodología de validación emplea una división de datos optimizada y ajuste de parámetros individuales. El modelo final integra LR, RF y SVM mediante un mecanismo de **Votación Ponderada (Weighted Voting)**, donde los pesos se asignan según el rendimiento individual. El sistema alcanzó un Accuracy del 98% y un Recall del 99%, demostrando que la combinación de modelos lineales y no lineales compensa las debilidades individuales de cada algoritmo.

C. Estudio Comparativo con Stratified Shuffle Split

Un enfoque reciente en el *Journal of Radiation Research and Applied Sciences* (Elsevier) por Ünalán et al. [10] analiza el impacto de las técnicas de validación en el rendimiento de los modelos. Bajo un paradigma supervisado, los autores comparan algoritmos de Boosting como LGBM, AdaBoost, GBM y RGF. La innovación reside en el uso de **Stratified Shuffle Split (SSS)** frente a la validación cruzada K-fold convencional. SSS es una técnica de validación que combina el barajado aleatorio con la estratificación, asegurando que la proporción de clases se mantenga constante en cada partición. Las métricas empleadas incluyen el área bajo la curva ROC (AUC) y el F1-score. Los resultados indicaron que el modelo LGBM individual alcanzó un F1-score del 99.2%, mientras

TABLE II: Comparativa de Trabajos Relacionados en el Estado del Arte

Trabajo	Paradigma	Técnicas Clave	Validación	Métrica Destacada	Resultado (Acc/Rec)
Rashed <i>et al.</i> [8]	Supervisado	AutoML (Lazy Predict)	CV / Hold-out	F1-Score	> 97% Acc
Martínez-Licort [9]	Ensemble	Weighted Voting (SVM+RF+LR)	Data Split Opt.	Recall	98% Acc / 99% Rec
Ünalán <i>et al.</i> [10]	Ensemble	LGBM / SSS Validation	Stratified Shuffle	AUC	99.5% Acc
Alam <i>et al.</i> [11]	Supervisado	Relief + SVM	K-fold / McNemar	McNemar Test	99.91% Acc

que el ensamble de AdaBoost, GBM y RGF logró un Accuracy del 99.5%, identificando la "textura peor" y los "puntos cóncavos peores" como las características más discriminantes.

D. Selección de Características Supervisada y No Supervisada

Finalmente, Alam *et al.* [11] en IEEE Access proponen un método que combina técnicas de selección de características supervisadas (algoritmo Relief) y no supervisadas (Autoencoders y PCA). El paradigma es **Aprendizaje Supervisado** utilizando SVM como clasificador base. La metodología de validación emplea K-fold cross-validation para la selección de hiperparámetros. Además de las métricas estándar, los autores utilizan la prueba estadística de **McNemar**, definida como:

$$\chi^2 = \frac{(|f_{12} - f_{21}| - 1)^2}{f_{12} + f_{21}}$$

Donde f_{12} son los casos clasificados correctamente por el modelo 1 pero no por el 2, y f_{21} viceversa. Esta métrica evalúa si la diferencia de rendimiento entre dos modelos es estadísticamente significativa.

Los resultados revelaron que la integración de **Relief-SVM** fue superior a los enfoques basados en PCA o Autoencoders, alcanzando una precisión excepcional del 99.91%. El estudio concluye que la selección de características orientada a la relevancia (Relief) es más efectiva que la reducción de varianza pura para este problema clínico.

En TABLE II se presenta el resumen de los trabajos relacionados y sus resultados.

III. ENTRENAMIENTO Y EVALUACIÓN DE LOS MODELOS

Esta sección detalla el diseño experimental, la configuración técnica y los resultados obtenidos durante la fase de simulación. El enfoque principal ha sido la optimización de la sensibilidad clínica (Recall) para garantizar la detección efectiva de tumores malignos, minimizando los riesgos asociados a diagnósticos erróneos.

A. Configuración Experimental

1) Metodología de Validación

Para garantizar la robustez estadística y la capacidad de generalización de los modelos, se implementó una metodología de validación basada en la partición de datos y validación cruzada estratificada. El proceso se estructuró en las siguientes etapas fundamentales:

- **Partición de Datos (Hold-out):** El dataset original de 569 muestras se dividió en un conjunto de entrenamiento (80%, correspondiente a 455 muestras) y

un conjunto de prueba independiente (20%, correspondiente a 114 muestras). Se utilizó un esquema de **muestreo estratificado** para asegurar que la proporción de clases (37.26% malignos, 62.74% benignos) se mantuviera idéntica en ambos subconjuntos. Esta partición es crítica para evaluar el desempeño real del sistema sobre datos que nunca fueron vistos durante el ajuste de parámetros.




Fig. 1. Gráficos de Distribución de Clases.

- **Validación Cruzada (K-Fold Cross-Validation):** Durante la fase de entrenamiento, se aplicó una validación cruzada de 5 pliegues (5-fold CV). En este proceso, el conjunto de entrenamiento se divide en 5 subpartes; el modelo se entrena en 4 y se valida en la restante, repitiendo el ciclo 5 veces. Esta técnica permite estimar el rendimiento esperado del modelo y su estabilidad mediante intervalos de confianza, reduciendo la varianza asociada a una única partición.
- **Reproducibilidad Técnica:** Se fijó una semilla aleatoria (random_state = 30) en todas las etapas de partición y entrenamiento para garantizar que los resultados sean reproducibles por otros investigadores.

Debido a que el dataset Wisconsin presenta un desbalance moderado pero no crítico (proporción aproximada de 1.7:1), el equipo decidió no aplicar técnicas de submuestreo o sobremuestreo (SMOTE), optando en su lugar por el ajuste de hiperparámetros y el uso de métricas de evaluación robustas que penalizan el error en la clase minoritaria (maligna).

2) Malla de Hiperparámetros (Grid Search)

La optimización de los modelos se realizó mediante una búsqueda exhaustiva en rejilla (GridSearchCV). Este proceso permite evaluar sistemáticamente múltiples combinaciones de parámetros para identificar la configuración que maximiza el Recall. En TABLE III se detalla la configuración de la malla de valores analizada para cada algoritmo implementado.

3) Métricas de Desempeño y Justificación Clínica

La evaluación del sistema se fundamentó en cuatro métricas clave, con una jerarquía de importancia definida por el contexto de la salud oncológica:

TABLE III: Malla de Hiperparámetros y Configuración de Modelos para la Optimización

Modelo	Hiperparámetro	Malla de Valores Evaluada	Justificación Técnica
Regresión Logística	C	[0.001, 0.01, 0.1, 1, 10, 100]	Controla el inverso de la fuerza de regularización para evitar overfitting.
	solver	['lbfgs', 'liblinear']	Algoritmo de optimización para asegurar la convergencia en diferentes espacios.
SVM (Support Vector Machine)	C	[0.1, 1, 10, 100]	Penalización del error y ajuste del margen de separación entre clases.
	gamma	[1, 0.1, 0.01, 0.001]	Define la curvatura de la frontera de decisión en el kernel RBF.
	kernel	['rbf', 'poly', 'sigmoid']	Determina el tipo de transformación espacial para separar los datos.
K-NN (K-Nearest Neighbors)	n_neighbors	[3, 5, 7, 9, 11, 13, 15]	Número de vecinos considerados para la clasificación local.
	weights	['uniform', 'distance']	Determina si la distancia influye en la importancia del voto del vecino.
Random Forest	n_estimators	[50, 100, 200]	Número de árboles de decisión en el bosque para reducir la varianza.
	max_depth	[None, 10, 20, 30]	Límite de crecimiento de los árboles para prevenir la memorización.
Red Neuronal (MLP)	hidden_layer_sizes	[(50,), (100,), (50, 50)]	Define la profundidad y complejidad de la arquitectura neuronal.
	activation	['tanh', 'relu']	Función de activación que permite aprender relaciones no lineales.
	alpha	[0.0001, 0.05]	Parámetro de regularización L2 para controlar la magnitud de los pesos.

- **Recall (Sensibilidad):** Es la métrica primaria del proyecto. Define la capacidad del modelo para identificar correctamente todos los casos positivos (malignos).

$$Recall = \frac{TP}{TP + FN}$$

Justificación: En oncología, un Falso Negativo (FN) implica un cáncer no detectado, lo cual es inaceptable. Se busca maximizar esta métrica incluso a riesgo de aumentar ligeramente los Falsos Positivos.

- **F1-Score:** Proporciona un equilibrio armónico entre Precision y Recall.

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Justificación: Es la métrica de referencia para comparar modelos de forma global cuando existe un desbalance de clases, asegurando que el modelo sea robusto en ambas dimensiones.

- **Accuracy (Exactitud):** Porcentaje total de predicciones correctas sobre el total de casos. *Justificación:* Proporciona una visión general del rendimiento, aunque se utiliza como métrica secundaria debido a su sensibilidad al desbalance de clases.
- **Precision (Precisión):** Capacidad de no clasificar como maligno un tumor que en realidad es benigno. *Justificación:* Su importancia radica en minimizar la realización de biopsias innecesarias y reducir el estrés emocional injustificado en el paciente.

B. Exploración y Análisis de Datos (EDA)

Antes del entrenamiento de los modelos, se llevó a cabo un Análisis Exploratorio de Datos (EDA) exhaustivo. Este procedimiento es fundamental para comprender la naturaleza

de las variables morfológicas y garantizar la integridad de los datos clínicos.

1) Procedimiento de Limpieza y Adecuación

El dataset se importó directamente del repositorio UCI Machine Learning. Aunque el conjunto de datos Wisconsin es reconocido por su alta calidad, se aplicaron los siguientes pasos de adecuación:

- **Exclusión de Identificadores:** Se eliminó la columna de ID de los pacientes, ya que no posee valor predictivo y podría inducir a errores en algoritmos basados en distancias (como KNN).
- **Codificación Binaria:** La variable objetivo Diagnosis fue transformada de etiquetas categóricas ('M', 'B') a valores numéricos (1, 0).
- **Verificación de Integridad:** Se confirmó la ausencia total de valores faltantes, eliminando la necesidad de técnicas de imputación.

2) Análisis Estadístico y Visual

Se realizó un estudio de las distribuciones de las 30 variables continuas. Se observó que las características relacionadas con el tamaño (radio, perímetro, área) presentan distribuciones con sesgo positivo, lo que justifica la posterior aplicación de estandarización.

3) Detección de Outliers con Isolation Forest

Una etapa innovadora en este proyecto fue la detección de valores atípicos utilizando el algoritmo **Isolation Forest**. A diferencia de los métodos estadísticos tradicionales (como el Z-score), Isolation Forest es un método no paramétrico que aísla anomalías en espacios multidimensionales. Se identificaron muestras con características morfológicas extremas que, aunque biológicamente posibles, podrían actuar como ruido para modelos sensibles a valores atípicos.

TABLE IV: Resultados Comparativos de Regresión Logística Según el Escenario de Datos

Escenario de Datos	Mejores Parámetros	Tiempo (s)	Recall CV	Recall TEST	F1-Score	Precisión	Accuracy
1. Crudo (30 var)	{'C': 1, 'solver': 'lbfgs'}	6.50	95.29% ($\pm 3.99\%$)	97.62%	96.47%	95.35%	97.37%
2. LASSO (15 var)	{'C': 1, 'solver': 'liblin'}	0.10	95.29% ($\pm 3.00\%$)	100.00%	98.82%	97.67%	99.12%
3. Mutual Info (15 var)	{'C': 1, 'solver': 'liblin'}	0.10	92.35% ($\pm 3.00\%$)	97.62%	93.18%	89.13%	94.74%
4. RFE (15 var)	{'C': 10, 'solver': 'liblin'}	0.09	95.88% ($\pm 4.40\%$)	97.62%	94.25%	91.11%	95.61%
5. PCA (10 comp)	{'C': 1, 'solver': 'liblin'}	0.09	95.88% ($\pm 3.53\%$)	97.62%	98.80%	100.00%	99.12%
6. Fisher (1 comp)	{'C': 10, 'solver': 'liblin'}	0.08	95.29% ($\pm 1.44\%$)	97.62%	98.80%	100.00%	99.12%

TABLE V: Resultados Comparativos de la Máquina de Vectores de Soporte (SVM) Según el Escenario de Datos

Escenario de Datos	Mejores Parámetros	Tiempo (s)	Recall CV	Recall TEST	F1-Score	Precisión	Accuracy
1. Crudo (30 var)	{'C': 10, 'g': 'scale', 'k': 'rbf'}	0.15	96.47% ($\pm 1.18\%$)	95.24%	96.39%	97.56%	97.37%
2. LASSO (15 var)	{'C': 1, 'g': 'scale', 'k': 'linear'}	0.11	96.47% ($\pm 2.20\%$)	95.24%	95.24%	95.24%	96.49%
3. Mutual Info (15 var)	{'C': 10, 'g': 'scale', 'k': 'rbf'}	0.12	94.12% ($\pm 3.72\%$)	95.24%	94.12%	93.02%	95.61%
4. RFE (15 var)	{'C': 10, 'g': 'scale', 'k': 'linear'}	0.11	95.88% ($\pm 4.40\%$)	97.62%	94.25%	91.11%	95.61%
5. PCA (10 comp)	{'C': 10, 'g': 'scale', 'k': 'rbf'}	0.10	95.88% ($\pm 1.44\%$)	92.86%	95.12%	97.50%	96.49%
6. Fisher (1 comp)	{'C': 10, 'g': 'auto', 'k': 'rbf'}	0.09	96.47% ($\pm 2.20\%$)	97.62%	97.62%	97.62%	98.25%

C. Resultados del Entrenamiento y Simulación

A continuación, se presentan los resultados detallados de la experimentación multiescenario. Los valores reportados para la fase de validación incluyen el intervalo de confianza (Media $\pm$ Desviación Estándar) obtenido tras el proceso de 5-fold CV, lo que permite evaluar la estabilidad del aprendizaje.

1) Análisis Regresión Logística

La Regresión Logística (RL) destaca ante variables independientes, pero decae bajo multicolinealidad. El Escenario 2 (LASSO) alcanzó la perfección clínica (100% Recall, 99.12% Accuracy) al eliminar variables redundantes y entregar un espacio ortogonal limpio. En contraste, Mutual Information fracasó (94.74% Accuracy) al seleccionar características altamente colineales que confundieron los coeficientes lineales. Por su parte, PCA y Fisher lograron un sobresaliente 99.12% de exactitud mediante transformaciones espaciales, aunque perdieron una mínima varianza morfológica. En conclusión, RL es óptima si se alimenta con características estrictamente descorrelacionadas. TABLE IV

2) Análisis Support Vector Machines (SVM)

El SVM busca maximizar el margen de separación entre clases, mostrando alta sensibilidad a la distribución espacial. Su mejor resultado ocurrió con Fisher (Escenario 6), alcanzando 98.25% de exactitud y 97.62% de Recall. Esto es teóricamente esperado, ya que Fisher maximiza la separación interclase, facilitando al SVM la definición de un punto de corte óptimo. No obstante, el SVM mostró una limitación clínica: ningún escenario logró 100% de Recall. Al penalizar por igual los errores, un caso maligno atípico quedó siempre clasificado como benigno.. TABLE V

3) Análisis K-Nearest Neighbors (KNN)

KNN, basado en distancias geométricas, es altamente sensible a la escala y la redundancia. El escenario con Mutual Information colapsó (92.11% Accuracy) porque las variables colineales de tamaño distorsionaron el cálculo de distancias, eclipsando factores sutiles. En

contraste, el set Crudo (30 variables) destacó (99.12% Accuracy) gracias a la métrica Manhattan (L_1), que mitigó el ruido. Asimismo, Fisher (1 componente) simplificó el cálculo a una sola dimensión pre-separada, haciendo que la búsqueda de vecinos fuera trivial y altamente efectiva (98.25% Accuracy).TABLE VI

4) Análisis Random Forest

Random Forest (RF) destaca por su robustez ante la alta dimensionalidad, pero sufre con variables ruidosas. El método Wrapper (RFE) logró el 100% de Recall (98.25% Accuracy) al entregarle 15 variables depuradas que optimizaron las divisiones de los nodos. Por el contrario, PCA redujo el rendimiento (93.86% Accuracy); las combinaciones lineales densas y abstractas dificultan que los árboles encuentren umbrales físicos claros. Finalmente, con Fisher obtuvo un 97.62% de Recall, aunque aplicar este ensamble sobre una sola dimensión subutiliza su capacidad multivariada.. TABLE VII

5) Análisis Redes Neuronales (MLP)

El Perceptrón Multicapa (MLP) aproxima funciones universales y modela fronteras de decisión complejas. En el escenario ideal (RFE), alcanzó 100% de Recall y 98.25% de exactitud; al recibir señales puras y sin ruido, las capas ocultas evitaron mínimos locales en el descenso del gradiente. Respecto a la eficiencia computacional, Fisher redujo el tiempo de entrenamiento de 7.44 a 2.36 segundos frente a Mutual Information, logrando un 97.62% de Recall. Esto demuestra el valor de la extracción supervisada en entornos con recursos limitados. TABLE VIII

IV. REDUCCIÓN DE DIMENSIÓN Y COMPLEJIDAD

La reducción de dimensionalidad es un paso imperativo en el diseño de sistemas de aprendizaje de máquina para aplicaciones médicas, ya que permite simplificar la arquitectura del modelo, reducir el costo computacional y mitigar el riesgo de sobreajuste (*overfitting*). En esta sección, evaluamos la capacidad discriminativa de las variables originales y contrastamos

TABLE VI: Resultados Comparativos del Clasificador K-NN Según el Escenario de Datos

Escenario de Datos	Mejores Parámetros	Tiempo (s)	Recall CV	Recall TEST	F1-Score	Precisión	Accuracy
1. Crudo (30 var)	{'m': 'manhattan', 'n': 3, 'w': 'dist'}	0.37	94.12% ($\pm 1.86\%$)	97.62%	98.80%	100.00%	99.12%
2. LASSO (15 var)	{'m': 'manhattan', 'n': 3, 'w': 'dist'}	0.16	92.94% ($\pm 3.99\%$)	95.24%	96.39%	97.56%	97.37%
3. Mutual Info (15 var)	{'m': 'euclidean', 'n': 3, 'w': 'dist'}	0.16	91.18% ($\pm 4.56\%$)	90.48%	89.41%	88.37%	92.11%
4. RFE (15 var)	{'m': 'manhattan', 'n': 9, 'w': 'dist'}	0.17	92.94% ($\pm 3.00\%$)	97.62%	97.62%	97.62%	98.25%
5. PCA (10 comp)	{'m': 'manhattan', 'n': 3, 'w': 'dist'}	0.15	92.94% ($\pm 3.00\%$)	95.24%	95.24%	95.24%	96.49%
6. Fisher (1 comp)	{'m': 'euclidean', 'n': 7, 'w': 'dist'}	0.14	96.47% ($\pm 2.20\%$)	97.62%	97.62%	97.62%	98.25%

TABLE VII: Resultados Comparativos de Random Forest Según el Escenario de Datos

Escenario de Datos	Mejores Parámetros	Tiempo (s)	Recall CV	Recall TEST	F1-Score	Precisión	Accuracy
1. Crudo (30 var)	{'depth': None, 'min_spl': 2, 'n_est': 100}	5.72	90.59% ($\pm 2.88\%$)	100.00%	96.55%	93.33%	97.37%
2. LASSO (15 var)	{'depth': None, 'min_spl': 10, 'n_est': 100}	4.96	92.35% ($\pm 1.44\%$)	97.62%	94.25%	91.11%	95.61%
3. Mutual Info (15 var)	{'depth': None, 'min_spl': 10, 'n_est': 100}	4.90	91.76% ($\pm 3.43\%$)	95.24%	93.02%	90.91%	94.74%
4. RFE (15 var)	{'depth': None, 'min_spl': 2, 'n_est': 100}	4.94	91.18% ($\pm 1.86\%$)	100.00%	97.67%	95.45%	98.25%
5. PCA (10 comp)	{'depth': None, 'min_spl': 2, 'n_est': 100}	5.03	92.94% ($\pm 3.00\%$)	95.24%	91.95%	88.89%	93.86%
6. Fisher (1 comp)	{'depth': None, 'min_spl': 10, 'n_est': 100}	4.16	96.47% ($\pm 2.20\%$)	97.62%	96.47%	95.35%	97.37%

TABLE VIII: Resultados Comparativos de la Red Neuronal (MLP) Según el Escenario de Datos

Escenario de Datos	Mejores Parámetros	Tiempo (s)	Recall CV	Recall TEST	F1-Score	Precisión	Accuracy
1. Crudo (30 var)	{'act': 'relu', 'alfa': 0.01, 'layers': (100,)}	4.84	95.29% ($\pm 3.53\%$)	97.62%	97.62%	97.62%	98.25%
2. LASSO (15 var)	{'act': 'relu', 'alfa': 1e-4, 'layers': (50,)}	4.42	96.47% ($\pm 3.43\%$)	95.24%	96.39%	97.56%	97.37%
3. Mutual Info (15 var)	{'act': 'relu', 'alfa': 1e-4, 'layers': (50,)}	7.44	94.71% ($\pm 3.90\%$)	97.62%	94.25%	91.11%	95.61%
4. RFE (15 var)	{'act': 'relu', 'alfa': 1e-4, 'layers': (100,)}	5.07	95.88% ($\pm 4.40\%$)	100.00%	97.67%	95.45%	98.25%
5. PCA (10 comp)	{'act': 'relu', 'alfa': 1e-4, 'layers': (50,)}	4.64	96.47% ($\pm 3.43\%$)	95.24%	96.39%	97.56%	96.49%
6. Fisher (1 comp)	{'act': 'relu', 'alfa': 1e-4, 'layers': (50,)}	2.36	95.88% ($\pm 2.35\%$)	97.62%	97.62%	97.62%	98.25%

métodos de extracción de características lineales y no lineales para optimizar el sistema de detección de cáncer de mama.

A. Análisis Individual de Variables

Para comprender la estructura del dataset Wisconsin y su capacidad discriminativa, se realizó un análisis de colinealidad basado en el coeficiente de correlación de Pearson y un estudio de relevancia estadística.

1) *Identificación de Multicolinealidad:* El análisis reveló una redundancia extrema entre las variables morfológicas extraídas de las imágenes de FNA. Se identificaron 10 características con coeficientes de correlación superiores a **0.90**, lo que indica una dependencia lineal casi perfecta:

- **Grupo de Tamaño (Morfología Básica):** radius1, perimeter1, area1, radius3, perimeter3 y area3. Estas variables están vinculadas por leyes geométricas fundamentales; por ejemplo, el área y el perímetro son funciones directas del radio. Su inclusión simultánea no aporta información nueva y puede desestabilizar modelos lineales como la Regresión Logística.
- **Grupo de Forma (Irregularidad):** concave_points1, concavity1, concave_points3 y concavity3. Estas métricas capturan la severidad de las indentaciones en el contorno nuclear, presentando una alta redundancia entre los valores medios y los valores “peores”.

2) *Características Candidatas a Eliminación:* Para optimizar el rendimiento predictivo y reducir la complejidad del sistema, se diseñaron seis escenarios de datos basados en diferentes filosofías de selección y extracción de características.

1) Escenario 1: Datos Crudos (30 Variables)

Este escenario sirve como línea base de comparación.

Incluye la totalidad de las características originales extraídas de las imágenes de FNA, sometidas únicamente a un proceso de **estandarización (Z-score)**. La estandarización es estrictamente necesaria ya que variables como el area (con magnitudes de hasta 2500) dominarían injustamente sobre variables como smoothness (con magnitudes menores a 0.2), afectando la convergencia de los modelos.

2) Escenario 2: Selección Incrustada (LASSO - 15 Variables)

Se utilizó la regularización L1 (LASSO) integrada en una Regresión Logística para realizar una selección multivariada. Este método penaliza los coeficientes de las variables menos importantes, forzándolos a ser exactamente cero. Resultando en la eliminación del 50% de la dimensionalidad. Las variables sobrevivientes incluyen concave_points1, radius2, area3, concavity3.

3) Escenario 3: Selección No Lineal (Mutual Información - 15 Variables)

Se aplicó un filtro basado en la Información Mutua (MI), el cual mide la dependencia estadística entre cada característica y el diagnóstico utilizando conceptos de la entropía de Shannon.

- **Justificación:** A diferencia de LASSO, MI es capaz de capturar relaciones no lineales complejas, lo que lo hace ideal para alimentar modelos abstractos como Random Forest y Redes Neuronales.

- **Variables Clave:** Destacan las métricas de area, perimeter y concavity en sus versiones “mean” y “worst”.

4) Escenario 4: Método Wrapper (RFE - 15 Variables)

Se implementó la Eliminación Recursiva de Características (RFE) utilizando una Regresión Logística

como estimador base. Este método entrena el modelo repetidamente, eliminando en cada paso la variable con menor peso (coeficiente) hasta alcanzar el número deseado.

- **Configuración:** Se forzó la selección de exactamente 15 variables para permitir una comparación justa con los escenarios 2 y 3.

5) Escenario 5: Extracción No Supervisada (PCA - 10 Componentes)

El Análisis de Componentes Principales (PCA) transforma las 30 variables originales en un nuevo espacio de componentes ortogonales.

- **Criterio:** Se seleccionaron los componentes necesarios para explicar el 95% de la varianza total.
- **Resultado:** Solo 10 componentes fueron suficientes para retener casi toda la información clínica, eliminando la correlación entre variables al 100%.




Fig. 2. Gráfico de Varianza Explicada por Componentes Principales (PCA).

6) Escenario 6: Discriminante de Fisher (LDA - 1 Componente)

Se aplicó el Análisis Discriminante Lineal (LDA), también conocido como el criterio de Fisher. A diferencia de PCA, LDA es un método supervisado que busca proyectar los datos en un espacio que maximice la separación entre las clases (benigno vs. maligno) y minimice la dispersión interna de cada clase.

- **Resultado:** Se redujo la dimensionalidad a un único componente altamente discriminativo, ofreciendo la solución más simple en términos de complejidad computacional.

V. DISCUSIÓN Y CONCLUSIONES

A. Discusión de Resultados

El análisis comparativo multiescenario implementado en este estudio proporciona una comprensión profunda de cómo interactúan los algoritmos de Machine Learning con las diferentes estrategias de ingeniería y reducción de características en el contexto del diagnóstico oncológico.

- 1) **El Desafío de la Multicolinealidad y Modelos Lineales:** Tal como se evidenció en el Análisis Individual de Variables, el dataset Wisconsin presenta una redundancia extrema en los grupos de tamaño y forma (correlaciones > 0.90). Este fenómeno quedó perfectamente reflejado en el comportamiento de la Regresión Logística. En el Escenario 1 (Crudo), el

modelo se vio afectado por la colinealidad, mientras que en el Escenario 2 (LASSO), al forzar la eliminación del 50% de las variables y quedarse con descriptores clave como `concave_points1` y `area3`, el modelo alcanzó la perfección clínica (100% de Recall y 99.12% de Accuracy). Esto demuestra que las aproximaciones lineales son altamente competitivas si se depura rigurosamente el espacio de características.

2) Sensibilidad Geométrica y Limitaciones Clínicas (SVM y KNN):

Las Máquinas de Vectores de Soporte (SVM) y K-Nearest Neighbors (KNN) demostraron una dependencia crítica de la estructura espacial. SVM encontró su mejor rendimiento en el Escenario 6 (Fisher) con 98.25% de Accuracy, beneficiándose de la maximización de la separación interclase que realiza LDA. Sin embargo, SVM exhibió una limitación ética-clínica fundamental: en ningún escenario logró el 100% de Recall, debido a que su función de pérdida penaliza los errores por igual, dejando siempre un tumor maligno atípico mal clasificado. Por otro lado, KNN colapsó en el escenario de Mutual Information (92.11% Accuracy) debido a que las variables colineales de tamaño distorsionaron las métricas de distancia, aunque demostró robustez en el set Crudo empleando la distancia Manhattan (L_1), mitigando eficazmente el ruido multidimensional.

3) Estructuras No Lineales y Flexibilidad (Random Forest y MLP):

Los modelos basados en aproximaciones complejas respondieron de manera contrastante ante la abstracción de los datos. Random Forest brilló en el Escenario 4 (RFE) alcanzando un 100% de Recall, ya que el método wrapper le entregó 15 variables limpias ideales para divisiones físicas en sus nodos; no obstante, decayó notablemente con PCA, debido a que las combinaciones lineales abstractas dificultan la creación de umbrales de decisión claros en los árboles. En contraposición, el Perceptrón Multicapa (MLP) demostró ser el modelo más versátil: no solo logró el 100% de Recall y 98.25% de Accuracy bajo RFE al evitar mínimos locales en el descenso del gradiente, sino que también demostró una alta eficiencia computacional en el Escenario 6 (Fisher), reduciendo el tiempo de entrenamiento de 7.44 a solo 2.36 segundos en comparación con Mutual Information.

4) Comparación con el Estado del Arte:

Los resultados de esta investigación superan de forma consistente los marcos de referencia analizados. Mientras que aproximaciones híbridas complejas como la de Martínez-Licort et al. [9] requieren un ensamble por votación ponderada (LR+RF+SVM) para alcanzar un 99% de Recall y 98% de Accuracy, y propuestas de AutoML como la de Rashed et al. [8] rondan el 97% de exactitud, la arquitectura de Red Neuronal (MLP) o la Regresión Logística optimizada de este estudio logran un 100% de Recall en prueba independiente empleando un solo

modelo robusto combinado con RFE, LASSO o PCA (10 componentes). Esto valida que un diseño metodológico estricto y enfocado en la depuración del espacio de características es más eficiente que el incremento arbitrario de la complejidad algorítmica.

B. Conclusiones Finales

Tras el análisis, diseño y simulación del sistema de predicción basado en el dataset Wisconsin, se concluye lo siguiente:

- **Eficacia y Selección de Arquitecturas:** Se concluye que el Perceptrón Multicapa (MLP) y la Regresión Logística (esta última estrictamente bajo regularización L1) representan las soluciones óptimas para la clasificación de tumores de mama en el dataset Wisconsin. Ambos modelos lograron mitigar por completo los errores de Tipo II, alcanzando un Recall del 100% en el conjunto de prueba independiente, satisfaciendo el criterio clínico más exigente en oncología.
- **Impacto de la Reducción de Dimensionalidad:** Las técnicas de ingeniería de características no solo reducen la carga computacional, sino que actúan como un filtro crítico de ruido biológico. Métodos como LASSO y RFE demostraron que es viable prescindir del 50% de las variables originales sin comprometer la sensibilidad, mientras que la extracción lineal por PCA comprobó que solo 10 componentes son suficientes para capturar el 95% de la varianza matemática del problema, eliminando la correlación al 100%.
- **Compromiso Computacional y Viabilidad Técnica:** Se demostró la viabilidad de diseñar sistemas CAD (Diagnóstico Asistido por Computadora) altamente eficientes. El uso del Criterio de Fisher (LDA de 1 componente) redujo drásticamente la complejidad del espacio predictivo en un 66.6% y contrajo los tiempos de cómputo en las redes neuronales a menos de la mitad (2.36 segundos), consolidándose como una estrategia clave para la futura implementación de estos modelos en entornos médicos con recursos de infraestructura limitados o dispositivos embebidos en tiempo real.
- **Utilidad Clínica y Trabajo Futuro:** El sistema desarrollado se posiciona como una herramienta de soporte objetivo de alta fidelidad para mitigar la variabilidad en la interpretación humana de biopsias por aspiración con aguja fina (FNA). Como trabajo futuro, se hace imperativo evaluar estas configuraciones óptimas (MLP/RL + RFE/PCA) en datasets clínicos externos, multiinstitucionales y con mayores niveles de desbalance de clases, garantizando que la robustez, sensibilidad y capacidad de generalización encontradas se preserven ante la variabilidad de diferentes tecnologías de adquisición de imágenes médicas.

REFERENCES

- [1] W. H. Wolberg, W. N. Street, and O. L. Mangasarian, "Breast Cancer Wisconsin (Diagnostic) Data Set," UCI Machine Learning Repository, 1995. [Online]. Available: <https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic>
- [2] W. H. Wolberg, "Breast cancer diagnosis and prognosis via linear programming," *Operations Research*, vol. 43, no. 4, pp. 570–577, 1995.
- [3] N. S. Al-Milli, "Computer-aided detection of breast cancer on the Wisconsin dataset: An artificial neural networks approach," *Biomedical Signal Processing and Control*, vol. 68, p. 102738, 2021.
- [4] S. Aamir *et al.*, "Predicting Breast Cancer Leveraging Supervised Machine Learning Techniques," *International Journal of Environmental Research and Public Health*, vol. 19, no. 15, p. 9398, 2022.
- [5] D. S. Abdelminaam *et al.*, "Harnessing Machine Learning for Early Breast Cancer Detection: A Comparative Study on the Wisconsin Dataset," *IEEE Access*, vol. 13, pp. 1–15, 2025.
- [6] H. Karnati *et al.*, "Federated and Split Learning for Enhanced Breast Cancer Diagnosis using the WDBC Dataset," in *Proc. IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*, 2023, pp. 1044–1051.
- [7] W. N. Street, W. H. Wolberg, and O. L. Mangasarian, "Nuclear feature extraction for breast cancer diagnosis," in *Proc. IS&T/SPIE 1993 International Symposium on Electronic Imaging: Science and Technology*, 1993, vol. 1905, pp. 861–870.
- [8] A. E. Rashed, A. M. Elmorsy, and A. E. M. Atwa, "Comparative evaluation of automated machine learning techniques for breast cancer diagnosis," *Biomedical Signal Processing and Control*, vol. 86, p. 105016, 2023.
- [9] R. Martínez-Licort *et al.*, "Breast Carcinoma Prediction Through Integration of Machine Learning Models," *IEEE Access*, vol. 12, pp. 134635–134650, 2024.
- [10] S. Ünal *et al.*, "A comparative study on breast cancer classification with stratified shuffle split and K-fold cross validation via ensemble machine learning," *Journal of Radiation Research and Applied Sciences*, vol. 17, no. 4, p. 101080, 2024.
- [11] J. Alam *et al.*, "Detection of Breast Cancer Through Clinical Data Using Supervised and Unsupervised Feature Selection Techniques," *IEEE Access*, vol. 9, pp. 22090–22105, 2021.